Final Project

Data Engineer

M.Abdurrahman Shidiq

22 March, 2023

Digitalskola, Batch 11







Problem Statement

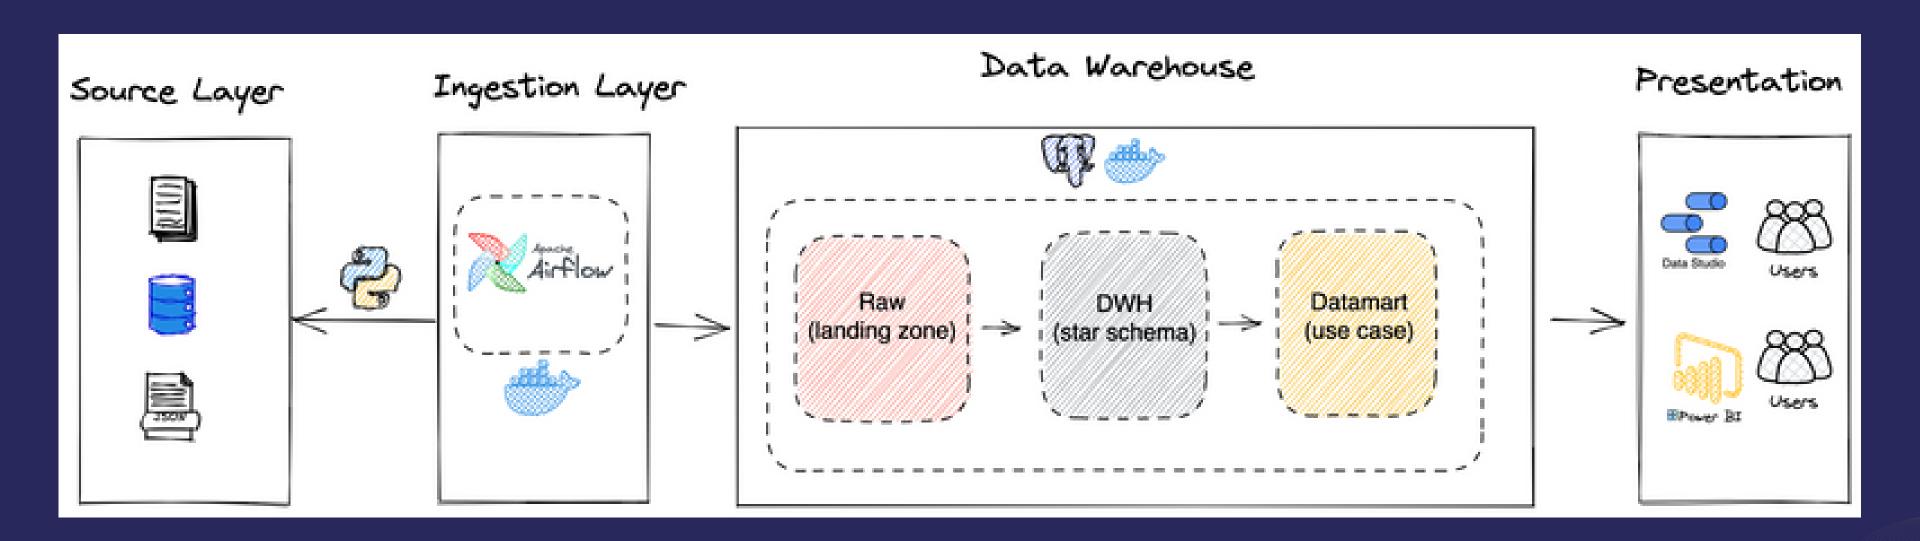
Sebagai Data Engineer, pada project ini kita diminta membangun sebuah data warehouse untuk kebutuhan analytics. Sehingga kebutuhan analisis bisa dilakukan pada OLAP bukan OLTP.

User ingin mendapatkan insight: Bagaiaman pengaruh curah hujan & suhu terhadap review / rating sebuah restaurant

Goals

- Data Ingestion
- Data Warehousing (star schema)
- Presentation Layer (Dashboard / insight)

Architecture High Level Diagram



Data Source

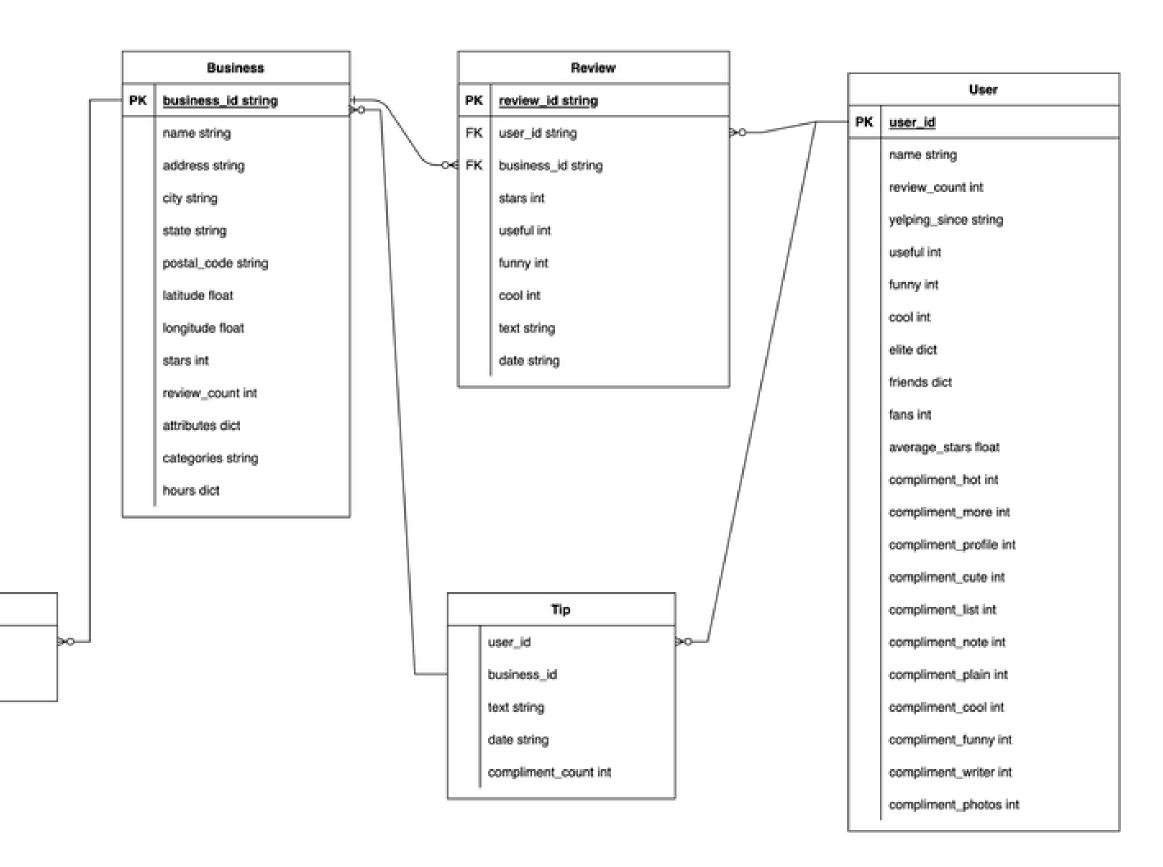
- Yelp Kaggle (JSON)
- Las Vegas Percipitation (CSV)

Checkin

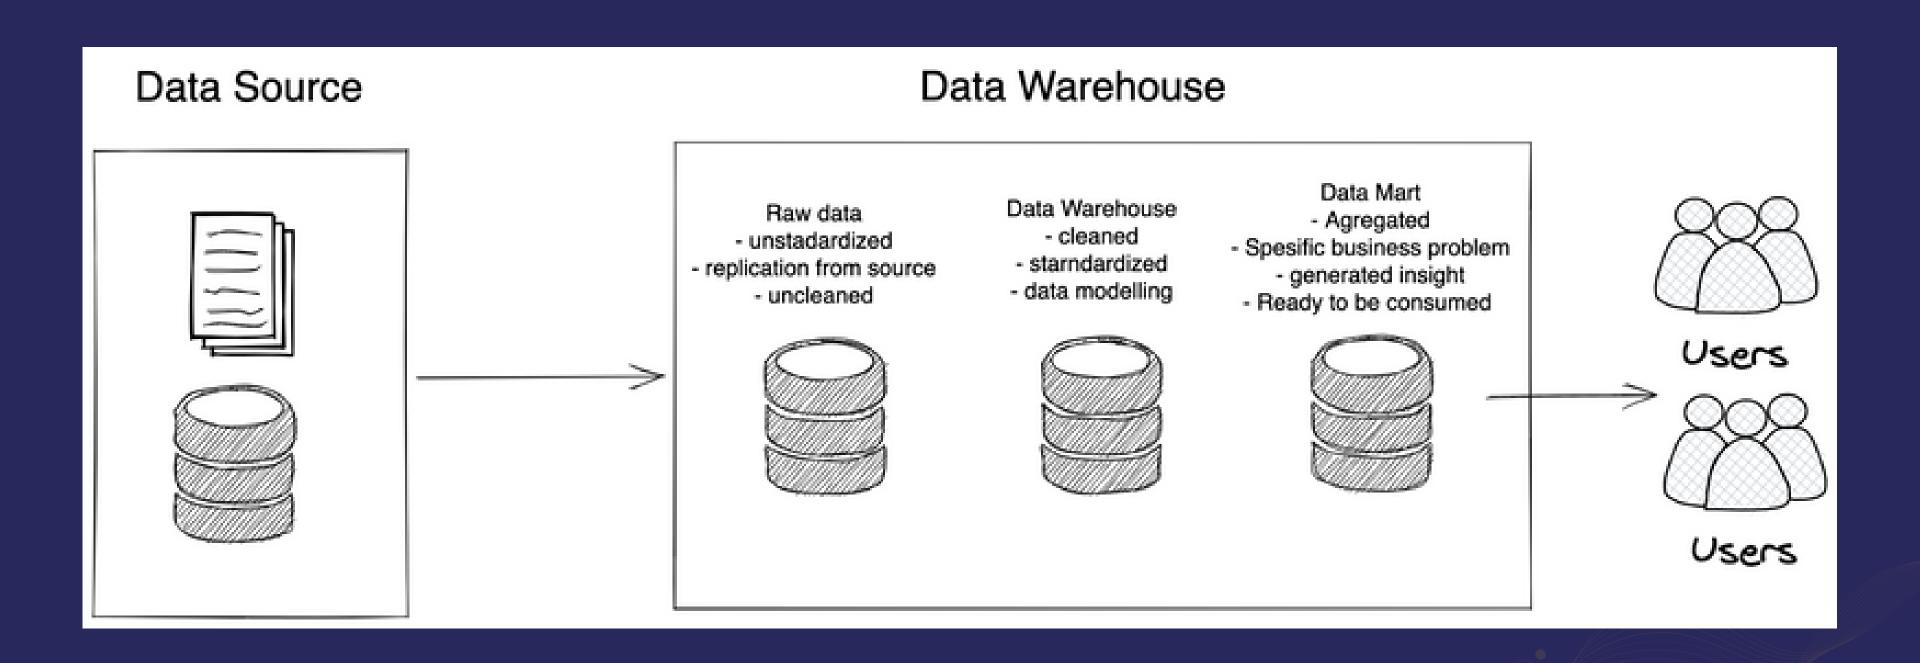
business_id

date string

• Temperature Degree (CSV)

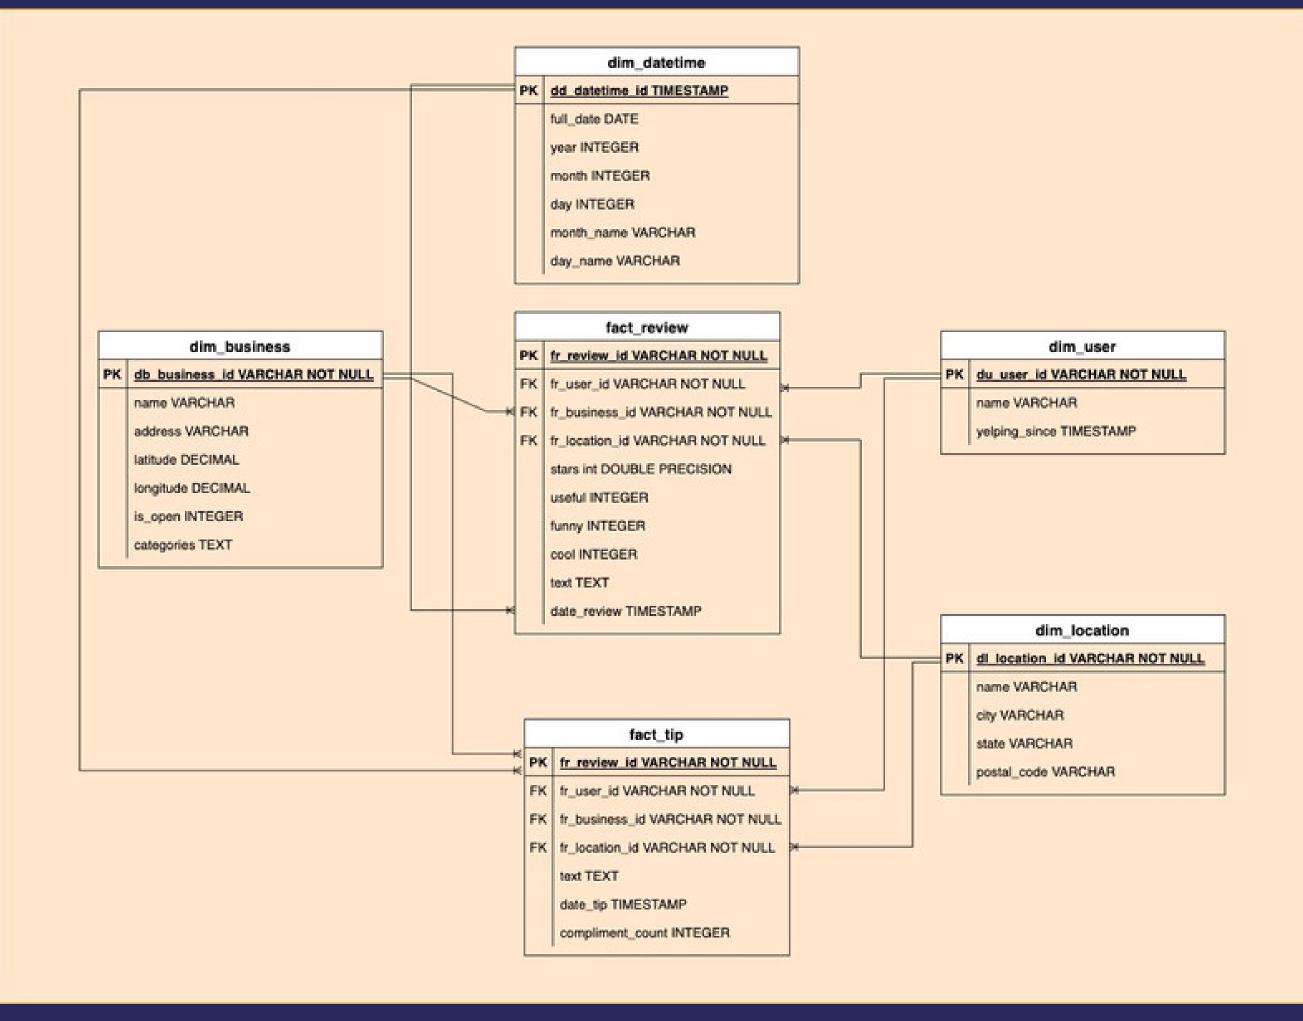


Architecture High Level Diagram



Data Modelling

Star Schema



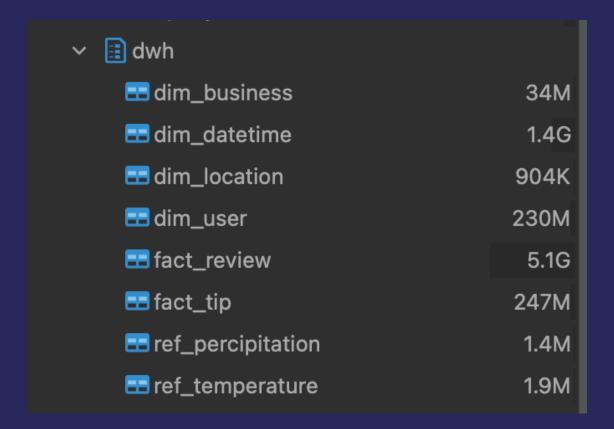
Data Warehouse Layer on Postgres

RAW Layer

✓ III raw business_stg_copy 5_stg 100M **u** business_stg_copy 8K 146M == checkin_stg 1.4M == percipitation_stg review_stg 4.6G == temperature_stg 1.9M == tip_stg 144M **user_stg** 2.9G

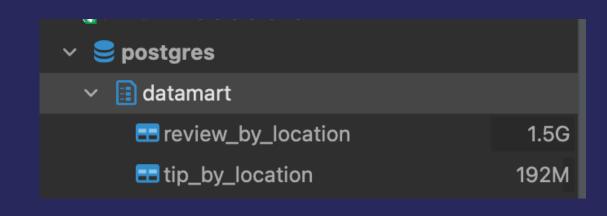
Data yang masuk apa adanya seperti sourcenya, dan seluruh tipe datanya dibuat `STRING`

DWH Layer



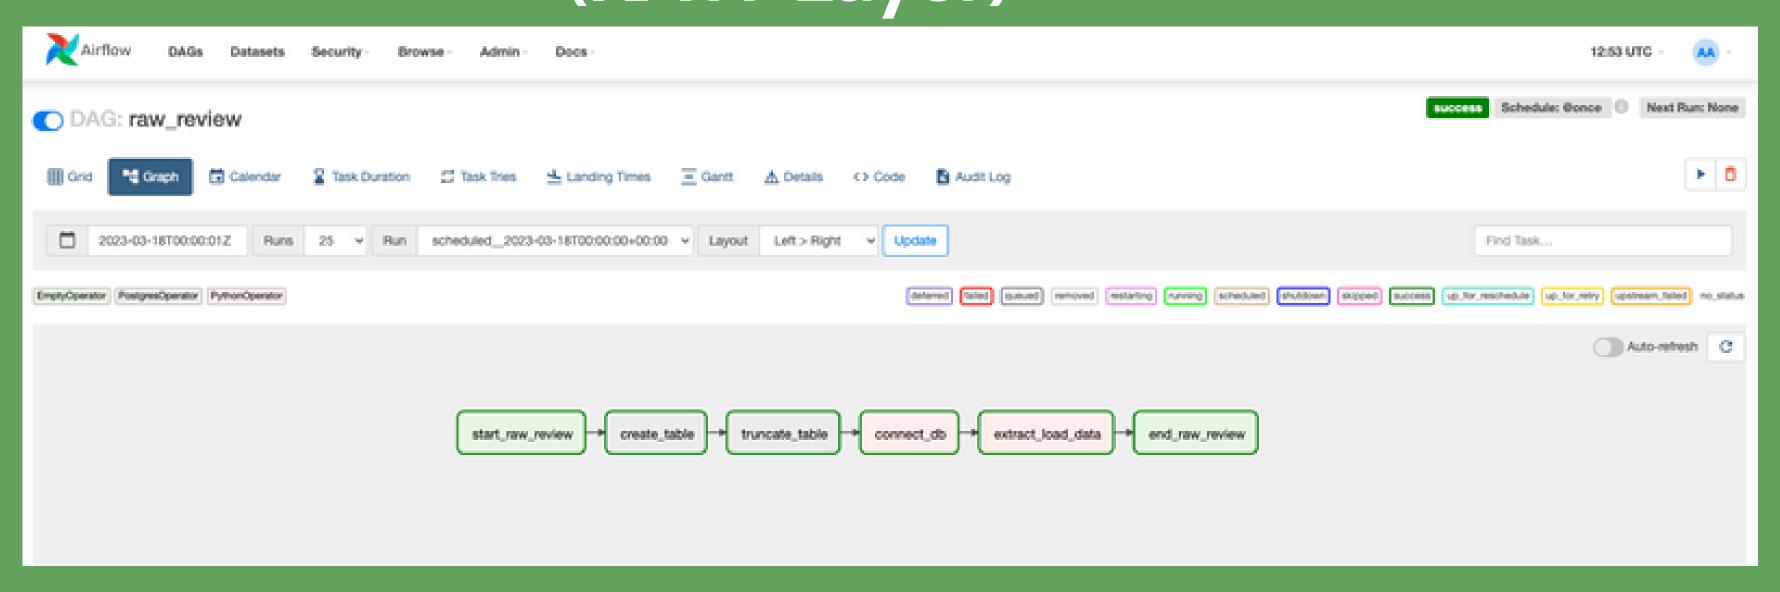
Dari Raw layer, data akan distandarkan tipe datanya, dilakukan modelling & cleansing

Datamart Layer



Model Datamart yang digunakan adalah One Big Table (OBT). Table-table di Data mart dibuat spesific menurut use casenya

Data Ingestion DAG (RAW Layer)

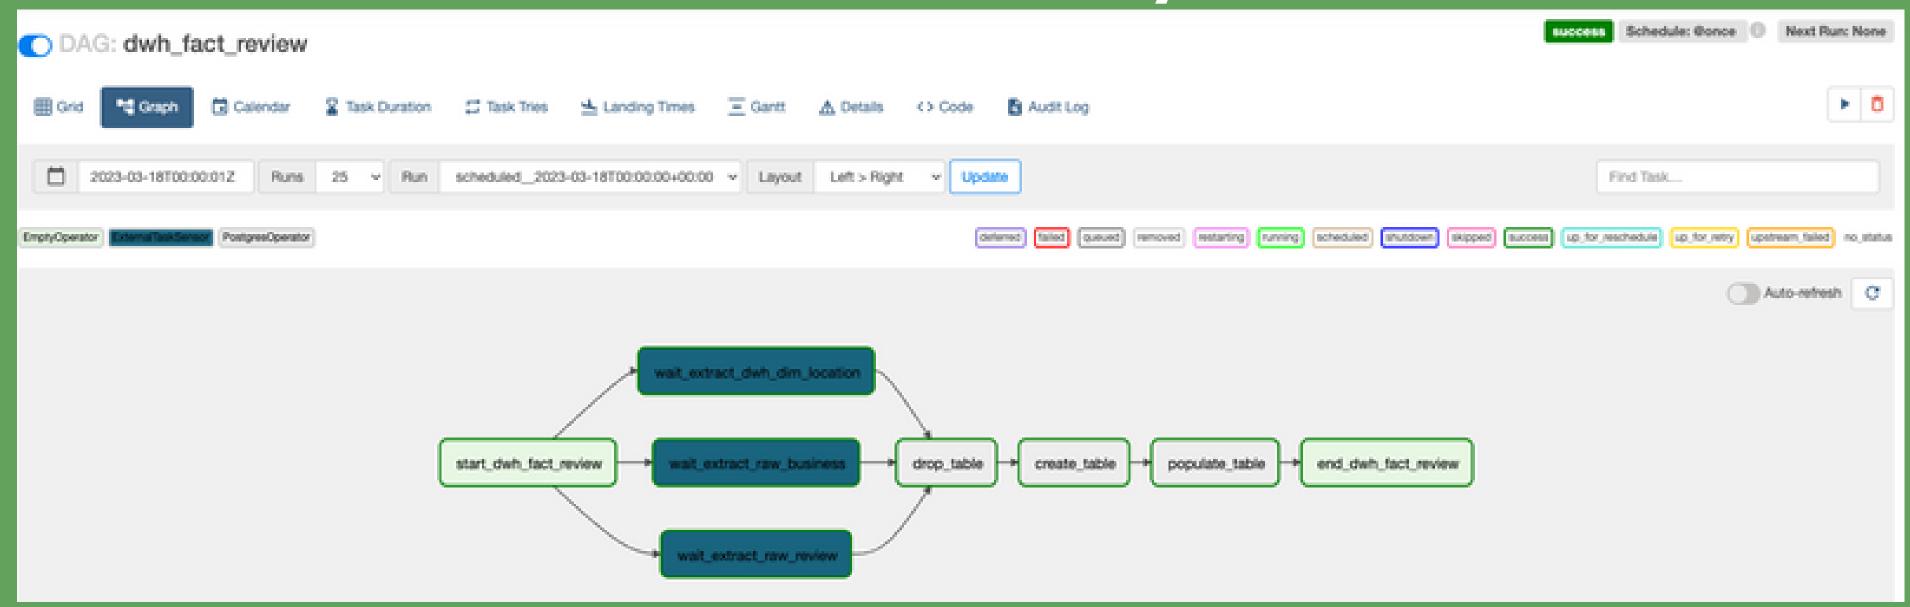


Airflow Operator

- EmptyOperator / DummyOperator
- PythonOperator
- PostgresOperator

Data Model DAG

(Data Warehouse Layer)

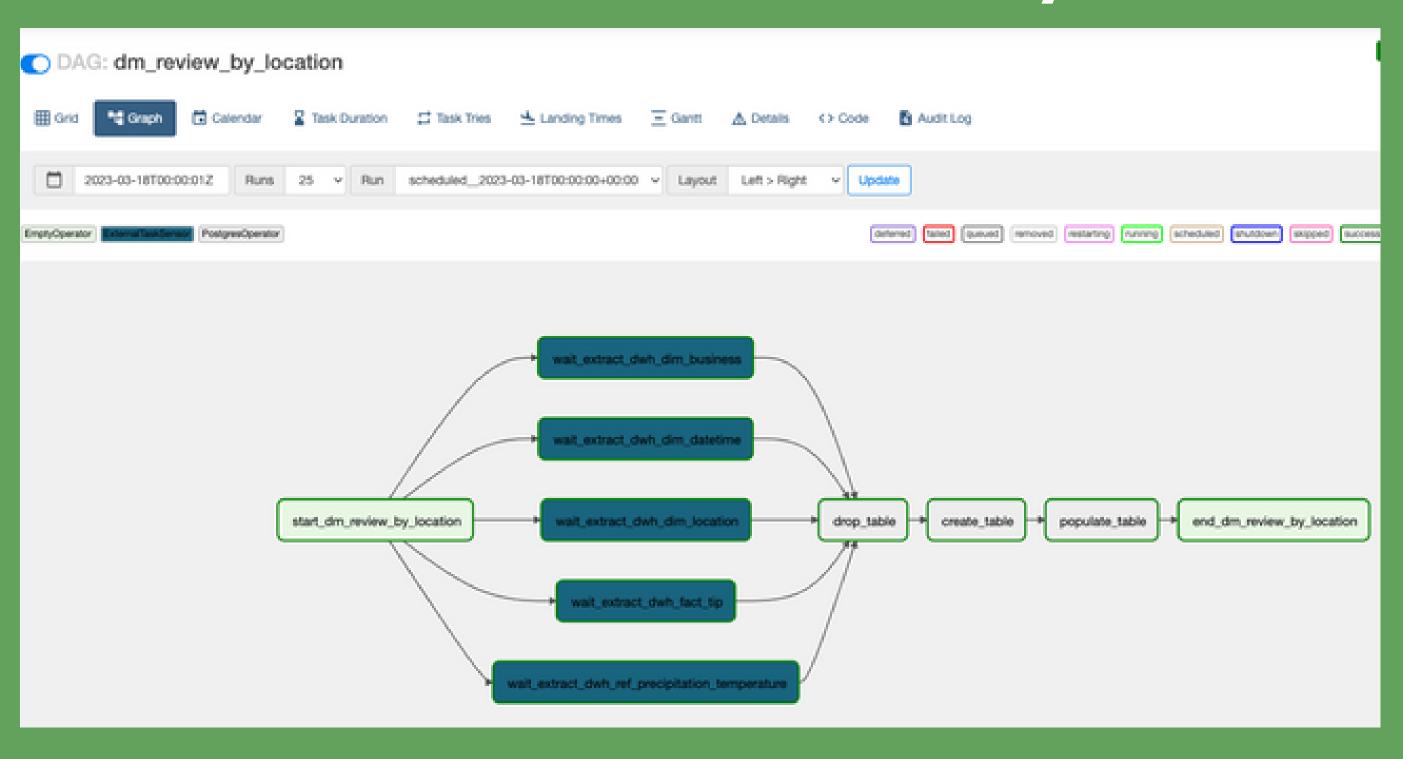


Airflow Operator

- ExternalTaskSensor
- EmptyOperator / DummyOperator
- PostgresOperator

Dengan menggunakan task sensoring, maka DAG diatas akan berjalan setelah DAG raw_business, raw_review (ingestion) & dim_location telah selesai. sehingga tidak ada task yang **OVERLAP** satu sama lain

Data Model DAG (Data Mart Layer)



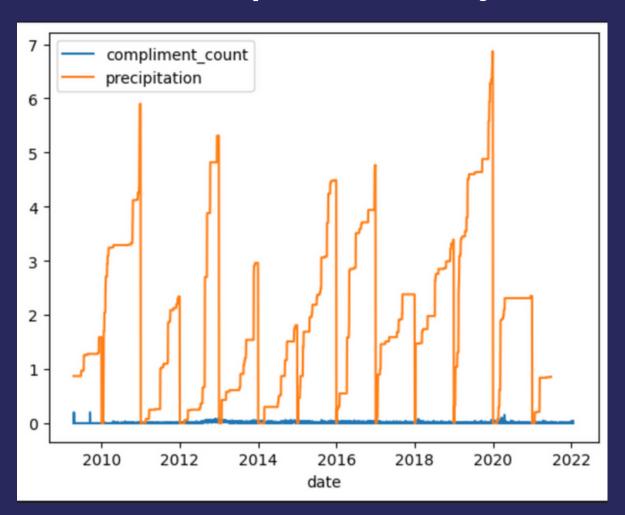
Airflow Operator

- ExternalTaskSensor
- EmptyOperator /DummyOperator
- PostgresOperator

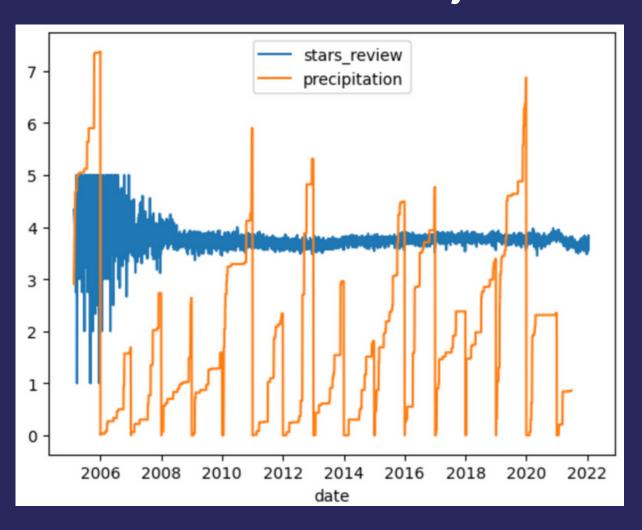
Analisa Hubungan Review / Tip dengan Curah Hujan

Analisa dilakukan dengan menggunakan table-table dari datamart

Jumlah Tip - Curah Hujan



Review - Curah Hujan



Dari chart di atas, dapat disimpulkan bahwa tidak ada hubungan yg siginifikan atau tidak ditemukan pattern yang jelas antara kedua variable tersebut

Github Repository

https://github.com/abdurrahmanshidiq/etl-dwh-project





Thankyou

Terima Kasih